Wpływ cech przestrzennych i strategii walidacji na dokładność predykcji cen najmu mieszkań z wykorzystaniem modelu CatBoost

Ivan Kokhman (104432)

Błażej Krasucki (103885)

Politechnika Opolska – kierunek Informatyka

Przedmiot: Rozpoznawanie wzorców

October 2026

Streszczenie

Przedmiotem planowanej pracy jest ocena wpływu cech przestrzennych oraz wyboru strategii walidacji na jakość predykcji cen najmu mieszkań. Badanie będzie realizowane na danych ogłoszeniowych dotyczących mieszkań w polskich miastach, zebranych w ramach projektu SmartRent AI. Porównane zostaną regresja liniowa jako model odniesienia i model CatBoost, trenowane zarówno na podstawowych cechach lokalu, jak i na zbiorze rozszerzonym o informacje przestrzenne. Zastosowane zostaną losowy podział danych oraz walidacja grupowa uwzględniająca lokalizację. Wyniki zostaną ocenione za pomocą MAE, RMSE i współczynnika R^2.

Repozytorium projektu: https://github.com/voloshka-eth/smart-rent

1 Temat, cel i uzasadnienie

Na cenę najmu mieszkania wpływają zarówno parametry lokalu, jak i jego położenie. Losowy podział danych może umieszczać podobne, sąsiednie oferty jednocześnie w zbiorach uczącym i testowym, prowadząc do optymistycznej oceny predykcji [1].

Cel pracy: ocenić wpływ cech przestrzennych i strategii walidacji na błąd predykcji ceny najmu.

1.1 Pytania badawcze i hipotezy

W ramach badania zostaną zweryfikowane następujące hipotezy:

- CatBoost osiągnie niższy MAE niż regresja liniowa.
- Dodanie cech przestrzennych zmniejszy błąd predykcji.
- Walidacja przestrzenna wykaże większy błąd niż podział losowy.

2 Opis zadania i dane wejściowe

Wykorzystane zostaną dane z projektu SmartRent AI: wstępnie około 18 tys. ogłoszeń z dziewięciu polskich miast. Po oczyszczeniu zbioru model otrzyma cechy mieszkania (miasto, dzielnica, powierzchnia, liczba pokoi, piętro i udogodnienia) oraz – w wariancie rozszerzonym – odległości do centrum, transportu i wybranych usług.

Przygotowanie danych obejmie deduplikację, odfiltrowanie błędnych ofert i ocenę jakości geolokalizacji. Celem predykcji jest cena ofertowa najmu w PLN miesięcznie, bez opłat administracyjnych. Zmienna `price_per_m2` zostanie wykluczona z predyktorów z uwagi na ryzyko przecieku informacji.

3 Planowana metodyka

Porównane zostaną regresja liniowa (model bazowy) oraz `CatBoostRegressor` [2]. Każdy model zostanie uruchomiony z podstawowym i przestrzennie rozszerzonym zestawem cech, co da łącznie cztery konfiguracje eksperymentu.

W ramach porównania zostaną zastosowane dwie strategie walidacji:

1. losowa walidacja krzyżowa;
2. walidacja grupowa, rozdzielająca obszary miasto–dzielnica pomiędzy foldy.

W obu strategiach wykorzystane będą identyczne konfiguracje modeli. Przygotowanie cech nastąpi wyłącznie na danych treningowych, aby ograniczyć ryzyko przecieku informacji.

Wyniki zostaną przedstawione za pomocą metryk MAE, RMSE i R^2, również w rozbiciu na poszczególne miasta.

4 Proponowane checkpointy

Tabela 1: Harmonogram realizacji projektu

Termin	**Etap**	**Oczekiwany rezultat / dowód wykonania**
27.10.2026	Checkpoint 1: dane i plan eksperymentu	Zweryfikowany zbiór danych, raport jakości geolokalizacji, lista cech i ustalony schemat podziałów.
24.11.2026	Checkpoint 2: modele i walidacja	Uruchomione modele bazowe i CatBoost, porównanie wariantów cech oraz tabela MAE/RMSE/R^2 dla obu schematów walidacji.
12.01.2027	Checkpoint 3: analiza wyników i artykuł	Interpretacja hipotez, wykresy i tabele, analiza ograniczeń oraz kompletna wersja miniartykułu.

5 Planowane rezultaty i kryteria zakończenia

Rezultatem projektu będzie artykuł zawierający tabelę metryk, opis eksperymentów, porównanie strategii walidacji oraz weryfikację postawionych hipotez.

Repozytorium będzie zawierać kod i parametry pozwalające odtworzyć wyniki. W opracowaniu zostaną opisane zarówno wyniki potwierdzające hipotezy, jak i wyniki im przeczące.

Literatura

[1] D. R. Roberts et al., "Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure," *Ecography*, vol. 40, no. 8, pp. 913–929, 2017. DOI: 10.1111/ecog.02881.

[2] L. Prokhorenkova et al., "CatBoost: Unbiased Boosting with Categorical Features," *Advances in Neural Information Processing Systems*, vol. 31, 2018.